

Principal Component Analysis

Simone Roldo
Matricola 238424

Angelo Trabucchi
Matricola 239778

1 Fondamenti teorici della PCA

L'analisi delle componenti principali (Principal Component Analysis - PCA) è una tecnica per la riduzione della dimensionalità di un set di dati caratterizzato da variabili correlate conservando la maggior quantità di informazione possibile. Essa è un metodo di analisi statistica di tipo non parametrico: a differenza degli approcci parametrici classici, questa metodologia non presuppone alcuna distribuzione probabilistica nota a priori (quale, ad esempio, una distribuzione normale, esponenziale o binomiale) per la stima dei parametri descrittivi. La PCA è particolarmente efficace nell'analisi di dataset complessi, caratterizzati da un elevato numero di variabili e da una ridondanza intrinseca.

1.1 Rappresentazione matriciale delle osservazioni

Si definisca un'osservazione p -dimensionale come un vettore riga $\mathbf{x} \in \mathbb{R}^p$ dove p è il numero di variabili osservate. Un dataset allora può essere rappresentato come una matrice $\mathbf{X} \in \mathbb{R}^{n \times p}$, costituita da n osservazioni p -dimensionali.

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_n \end{bmatrix} \quad (1)$$

In $\mathbf{X}$ i dati sono rappresentati rispetto alla base canonica, ma questa non è l'unica base ammissibile. Consideriamo una trasformazione lineare descrivibile mediante una matrice $\mathbf{W} \in \mathbb{R}^{p \times p}$; in tal caso $\mathbf{X}$ potrà essere riscritto nella base $\{\mathbf{w}_1, \dots, \mathbf{w}_p\}$ definita dalle colonne di $\mathbf{W}$ come:

$$\begin{bmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_n \end{bmatrix} = \mathbf{Y} = \mathbf{XW} = \begin{bmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_n \end{bmatrix} \begin{bmatrix} \mathbf{w}_1 & \dots & \mathbf{w}_p \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1 \cdot \mathbf{w}_1 & \dots & \mathbf{x}_1 \cdot \mathbf{w}_p \\ \vdots & & \vdots \\ \mathbf{x}_n \cdot \mathbf{w}_1 & \dots & \mathbf{x}_n \cdot \mathbf{w}_p \end{bmatrix} \quad (2)$$

In tale forma ogni riga $\mathbf{y}_i$ del nuovo dataset trasformato è ottenuta proiettando l'osservazione originale $\mathbf{x}_i$ sulle colonne di $\mathbf{W}$.

La PCA ricerca quindi la base ottimale $\{\mathbf{w}_1, \dots, \mathbf{w}_p\}$ per descrivere $\mathbf{X}$. Sebbene la definizione di ottimalità sia rimandata al seguito, è importante notare come tale approccio è intrinsecamente vincolato alla modellazione delle sole relazioni lineari tra i dati.

1.2 Ipotesi Statistica di ottimalità

Il criterio per determinare la matrice di trasformazione ottimale $\mathbf{W}$ si fonda sull'assunzione che l'informazione significativa di $\mathbf{X}$ sia codificata nelle direzioni di massima variabilità dei dati. Ciò equivale a ricercare la massimizzazione del rapporto segnale-rumore (Signal-to-Noise Ratio), definito come il quoziente tra la varianza della componente deterministica e quella della componente stocastica:

$$SNR = \frac{\sigma_{segnale}^2}{\sigma_{rumore}^2} \quad (3)$$

Un valore $SNR \gg 1$ indica una prevalenza dell'informazione strutturale rispetto al rumore di fondo. L'ipotesi forte della PCA stabilisce quindi un'equivalenza tra varianza e informazione: si assume che le dinamiche di interesse si manifestino lungo gli assi di maggiore dispersione statistica, mentre le direzioni a varianza minima siano dominate dal rumore.

Operativamente, ciò guida la costruzione della base vettoriale: le componenti principali sono definite come i vettori colonna $\{\mathbf{w}_1, \dots, \mathbf{w}_p\}$ della matrice $\mathbf{W}$ che, una volta utilizzati per proiettare i dati, massimizzano la varianza delle proiezioni lungo i nuovi assi. Tale ordinamento garantisce che le prime componenti catturino la quasi totalità della struttura informativa del dataset originale.

1.3 Centratura e matrice di covarianza

È preliminare alla PCA la centratura di $\mathbf{X}$ per imporre media nulla alle variabili, requisito necessario per l'analisi della varianza. Calcolato il vettore media $\boldsymbol{\mu} \in \mathbb{R}^p$ il dataset viene trasformato come segue:

$$\mathbf{X}_{centred} = \mathbf{X} - \mathbf{1}\boldsymbol{\mu}^T \quad (4)$$

dove $\mathbf{1}$ è un vettore colonna di tutti uno. Da ora in avanti si assumerà che $\mathbf{X}$ sia il dataset centrato.

Da $\mathbf{X}$, si definisce la matrice di covarianza campionaria $\mathbf{C}_X = \frac{1}{n-1}\mathbf{X}^T\mathbf{X}$ avente le seguenti proprietà:

- $\mathbf{C}_X \in \mathbb{R}^{p \times p}$: la matrice descrive le relazioni nello spazio delle variabili indipendentemente dal numero di osservazioni n .
- $\mathbf{C}_X = \mathbf{C}_X^T$: essendo una matrice simmetrica reale, per il teorema spettrale è ortogonalmente diagonalizzabile e possiede autovalori reali.
- L'elemento (j, j) rappresenta la varianza della j -esima variabile: valori elevati corrispondono a variabili più informative.
- L'elemento (i, j) con $i \neq j$ rappresenta la covarianza tra la variabile i e la variabile j : valori elevati in modulo corrispondono a coppie di variabili tra loro ridondanti.

1.4 PCA tramite covarianza

La PCA risolve il problema di trovare una matrice di trasformazione $\mathbf{W}$ tale che il nuovo dataset $\mathbf{Y} = \mathbf{X}\mathbf{W}$ possieda una matrice di covarianza $\mathbf{C}_Y$ con le seguenti proprietà:

- $\mathbf{C}_Y$ è diagonale. Questo implica che la covarianza tra le variabili sia nulla, garantendo l'incorrelazione.
- Gli elementi sulla diagonale, ovvero gli autovalori, sono ordinati in senso decrescente. Per l'ipotesi di ottimalità questo implica un ordinamento a contenuto informativo decrescente.

Teorema (Diagonalizzazione della Covarianza): Siano $\mathbf{X}$ un dataset centrato con matrice di covarianza $\mathbf{C}_X$, $\mathbf{E}$ la matrice ortogonale degli autovettori di $\mathbf{C}_X$ e $\mathbf{\Lambda}$ la matrice diagonale dei corrispondenti autovalori. Se si sceglie come matrice di trasformazione $\mathbf{W} = \mathbf{E}$, allora la matrice di covarianza del dataset trasformato $\mathbf{Y} = \mathbf{XW}$ è $\mathbf{C}_Y = \mathbf{\Lambda}$.

Dimostrazione

Poiché $\mathbf{C}_X$ è reale e simmetrica, per il teorema spettrale essa è ortogonalmente diagonalizzabile. Esistono quindi $\mathbf{E}$ ortogonale, contenente gli autovettori normalizzati di $\mathbf{C}_X$, e $\mathbf{\Lambda}$, contenente gli autovalori di $\mathbf{C}_X$, tali che $\mathbf{C}_X = \mathbf{E}\mathbf{\Lambda}\mathbf{E}^T$. Perciò:

$$\begin{aligned}
\mathbf{C}_Y &= \frac{1}{n-1} \mathbf{Y}^T \mathbf{Y} \\
&= \frac{1}{n-1} (\mathbf{XW})^T (\mathbf{XW}) \\
&= \mathbf{W}^T \left(\frac{1}{n-1} \mathbf{X}^T \mathbf{X} \right) \mathbf{W} \\
&= \mathbf{W}^T \mathbf{C}_X \mathbf{W} \\
&= \mathbf{E}^T (\mathbf{E}\mathbf{\Lambda}\mathbf{E}^T) \mathbf{E} \\
&= \mathbf{\Lambda} \mathbf{I} \mathbf{\Lambda} \\
&= \mathbf{\Lambda}
\end{aligned} \tag{5}$$

□

Il precedente teorema porta a concludere che la trasformazione $\mathbf{W}$ ha eliminato le covarianze tra le variabili, decorrelando i dati e dimostrando che le componenti principali coincidono con gli autovettori di $\mathbf{C}_X$.

1.5 PCA tramite SVD

Sebbene la PCA possa essere eseguita tramite covarianza, l'approccio computazionalmente migliore è legato alla decomposizione ai valori singolari (Singular Value Decomposition - SVD). Tale metodo permette di estrarre le componenti principali operando direttamente su $\mathbf{X}$, evitando il calcolo esplicito di $\mathbf{C}_X$ e migliorando la stabilità numerica.

Teorema (SVD):

Sia $\mathbf{X} \in \mathbb{R}^{n \times p}$ allora esistono:

- $\mathbf{U} \in \mathbb{R}^{n \times n}$ ortogonale i cui vettori colonna $\mathbf{u}_i$ sono detti vettori singolari sinistri.
- $\mathbf{\Sigma} \in \mathbb{R}^{n \times p}$ quasi-diagonale contenente i valori singolari $\sigma_i \geq 0$ sulla diagonale, ordinati in senso decrescente.
- $\mathbf{V} \in \mathbb{R}^{p \times p}$ ortogonale i cui vettori colonna $\mathbf{v}_i$ sono detti vettori singolari destri.

tali che $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$

La SVD risolve il problema della PCA poiché:

$$\begin{aligned}\mathbf{C}_X &= \frac{1}{n-1} \mathbf{X}^T \mathbf{X} \\ &= \frac{1}{n-1} (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T)^T (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T) \\ &= \mathbf{V} \left(\frac{\mathbf{\Sigma}^T \mathbf{\Sigma}}{n-1} \right) \mathbf{V}^T\end{aligned}\tag{6}$$

e confrontando questo risultato con $\mathbf{C}_X = \mathbf{E}\mathbf{\Lambda}\mathbf{E}^T$, si ha che:

- Le colonne di $\mathbf{V}$ coincidono con gli autovettori di $\mathbf{C}_X$, ovvero i vettori singolari destri della SVD coincidono con le componenti principali.
- I valori singolari σ_i sono legati agli autovalori λ_i di $\mathbf{C}_X$ dalla relazione $\lambda_i = \frac{\sigma_i^2}{n-1}$.

La superiorità numerica della SVD rispetto al metodo della covarianza è data dal numero di condizionamento $\kappa(\cdot)$ che misura la sensibilità della soluzione rispetto a piccole perturbazioni nei dati. Il numero di condizionamento di $\mathbf{X}$ è $\kappa(\mathbf{X}) = \frac{\sigma_{max}}{\sigma_{min}}$. Tuttavia, il metodo della covarianza calcola esplicitamente $\mathbf{X}^T \mathbf{X}$ elevando al quadrato il condizionamento poiché: $\kappa(\mathbf{X}^T \mathbf{X}) = (\kappa(\mathbf{X}))^2$. In dataset ad alta dimensionalità, dove $\kappa(\mathbf{X})$ è già elevato, il suo quadrato può superare la precisione macchina $\epsilon = 10^{-16}$, causando la perdita di cifre significative per gli autovalori minori. La SVD, operando direttamente su $\mathbf{X}$, preserva il condizionamento originale, garantendo robustezza numerica.

2 Implementazione computazionale della PCA

La validazione sperimentale della PCA è stata condotta attraverso l'implementazione in linguaggio python del modello teorico con l'obiettivo di costruire un sistema di riconoscimento facciale usando librerie di algebra lineare e di visualizzazione, quali NumPy e Matplotlib per esplicitare le operazioni algebriche descritte nel capitolo teorico, senza ricorrere a librerie nelle quali l'implementazione della PCA è già svolta internamente come scikit-learn

2.1 Creazione Dataset

Il dataset principale è costituito dall'Olivetti Research Laboratory Dataset, composto originariamente da gruppi di immagini di 40 soggetti, ciascuno rappresentato da 10 acquisizioni diverse per espressione facciale e condizioni di illuminazione. Ad esse è stato aggiunto un dataset personale della stessa struttura costituito da 4 soggetti. Questa aggiunta permette di verificare il comportamento dell'algoritmo su dati acquisiti con sensori moderni e condizioni ambientali non controllate.

Per ogni soggetto, 9 delle 10 immagini sono state allocate nel set di training per la costruzione della matrice di covarianza e il calcolo delle componenti principali che, rimodellate in matrici e visualizzate, sono note come eigenfaces. Il totale delle immagini di addestramento risulta quindi essere di $n = (40 \times 9) + (4 \times 9) = 396$ immagini. La decima immagine di ogni

soggetto è stata separata in un dataset di test, garantendo che la valutazione dell'efficacia del procedimento di proiezione avvenga su dati mai visti dal modello durante la fase di calcolo degli autovettori. Infine al set di test è stata aggiunta una singola immagine del volto dell'autore, deliberatamente assente dal training set per testare la robustezza del sistema nel rifiutare input sconosciuti.

Inizialmente tutte le immagini subiscono una serie di operazioni per conformarle alla struttura richiesta dalla PCA:

- Conversione in scala di grigi per trattare le immagini come matrici bidimensionali.
- Ridimensionamento e ritaglio delle immagini del dataset personale per portarle alla risoluzione del dataset Olivetti 92×112 pixel.
- Trasformazione delle matrici immagine in vettori riga $\mathbf{x} \in \mathbb{R}^p$, dove $p = 92 \times 112 = 10.304$, permettendo la costruzione del dataset $\mathbf{X}$.

2.2 Valutazione dell'efficienza dei metodi per la PCA

Una volta ottenuto $\mathbf{X}$, ed averlo centrato, viene effettuata la PCA, implementata nei tre metodi: covarianza, duale e SVD. Il metodo duale, che è stato omissso nella trattazione teorica, è analogo come idea a quello della covarianza ma sfrutta la proprietà algebrica per cui gli autovalori non nulli di $\mathbf{X}^T \mathbf{X} \in \mathbb{R}^{p \times p}$ coincidono con quelli di $\mathbf{X} \mathbf{X}^T \in \mathbb{R}^{n \times n}$, permettendo di calcolare gli autovettori ausiliari su una matrice ridotta.

Il calcolo del tempo di esecuzione al variare del procedimento scelto porta ad evidenziare come il metodo della covarianza sia quella più inefficiente (≈ 185 secondi) poiché la ricerca degli autovalori di $\mathbf{C}_X \in \mathbb{R}^{10304 \times 10304}$ richiede molto tempo data l'alta dimensionalità della matrice, sebbene sia simmetrica. Il metodo duale sfrutta il fatto che la ricerca di autovalori per $\mathbf{X} \mathbf{X}^T \in \mathbb{R}^{396 \times 396}$ è molto più semplice arrivando a prestazioni di ≈ 0.06 secondi; infine la SVD è anch'essa efficiente (≈ 0.32 secondi) poiché la sua implementazione, nella forma ridotta, si limita a calcolare le prime $n = 396$ componenti essendo che $\text{rank}(\mathbf{X}) \leq n = \min(n, p)$. Sebbene da questo test il metodo duale risulti il più veloce, data la struttura dimensionalmente sbilanciata di $\mathbf{X}$, rimane il fatto che la SVD è da preferire in quanto computazionalmente più stabile.

Indipendentemente dal metodo usato, la PCA produce la matrice di trasformazione $\mathbf{W}_k$ contenente i primi k autovettori, il vettore media $\boldsymbol{\mu}$ e i pesi dei dati di training $\mathbf{Y}$.

2.3 Esempio di applicazione

A seguito della effettiva computazione della PCA si è voluto mostrare un esempio di caso d'uso: il riconoscimento facciale. Data un'immagine dal dataset di test e omogeneizzata a quelle del dataset di Olivetti come descritto sopra si è ottenuto un vettore $\mathbf{x}_{test}$ al quale sono state effettuate le seguenti operazioni:

- Centratura e proiezione nel sottospazio del dato: $\mathbf{y}_{test} = (\mathbf{x}_{test} - \boldsymbol{\mu}) \mathbf{W}_k$.
- Calcolo della distanza euclidea $d_i = \|\mathbf{y}_{test} - \mathbf{y}_i\|_2$ tra la proiezione del nuovo dato e ogni riga di $\mathbf{Y}$
- Identificazione del soggetto corrispondente all'indice che minimizza la distanza.

- Verifica che tale distanza sia inferiore a una certa soglia determinata empiricamente oltre la quale l'immagine test è da considerare di un soggetto non riconoscibile o estraneo al dataset

Parallelamente al riconoscimento viene quantificata la perdita di informazione dovuta alla compressione. Per ogni scelta del numero di componenti k , l'immagine viene ricostruita retro-proiettandola nello spazio originale $\hat{\mathbf{x}}_{test} = \mathbf{y}_{test} \mathbf{W}_k^T + \boldsymbol{\mu}$. Attraverso il Mean Squared Error (MSE) e la varianza spiegata, ovvero la percentuale di informazione conservata sotto l'ipotesi di ottimalità, è stata quantificata la perdita di dettaglio introdotta dalla compressione dimensionale.

I risultati sono stati i seguenti:

- Utilizzando poche componenti ($k < 10$), le immagini ricostruite appaiono come approssimazioni sfocate, in cui sono preservate solo le macro-geometrie del volto ma si perdono i tratti somatici distintivi necessari all'identificazione.
- Aumentando le componenti, si osserva una riduzione dell'errore di ricostruzione. Il sistema recupera dettagli come occhi e bocca, raggiungendo un compromesso tra compressione e fedeltà visiva.

2.4 Conclusione

L'implementazione della PCA ha quindi permesso di validarne l'efficacia come strumento di compressione e classificazione biometrica, mostrando contemporaneamente la superiorità algoritmica della SVD rispetto all'approccio basato sulla covarianza.

L'analisi sulla ricostruzione delle immagini ha confermato la capacità della PCA di isolare le variabili strutturali fondamentali nelle prime componenti.